


# Optimierung

---

## Vorlesung 1 Einführung und Überblick

- Informatik befasst sich viel mit **Algorithmen**
- Noch vor dem Algorithmus steht jedoch das zu lösende **Problem**, welches man idealerweise formal sauber in Form eines **Modells** ausdrückt.
- Überspringt man die Modellierung, führt dies zu “Hacks” mit zahlreichen negativen Konsequenzen:
  - Zusammenhänge zwischen ähnlichen Problemen gehen verloren
  - Kombinationen und Erweiterungen werden sehr schnell sehr kompliziert
  - Theoretische Analyse und Garantien oft nicht möglich
- Konsequenter Zugang:
  - Formulierung des zu lösenden Problems  
(**Modell, Zielfunktion**)
  - Anwendung von passenden Algorithmen entsprechend der Problemklasse  
(**Optimierungsmethode**)

- Informatiker im Bankengewerbe, Auftrag: Erwarteter Gewinn Hausverkäufe
- Lösung 1: Einfach Erwartungswert bilden.
- Lösung 2: Sich die Verteilung ansehen -> Nachbarschaften



- Optimierungsproblem: Optimierte Parameter der beiden Verteilungen

- Basteln und Ausprobieren ist die kreative Seite der Wissenschaft
- Für komplexe Aufgaben reicht Kreativität alleine nicht aus
- Mache die Aufgabe erst so einfach wie möglich
  - das Wesentliche erkennen
  - Zusammenhänge zu bekannten Lösungen sehen
  - bekannte Analysen und Eigenschaften nutzen
- Übrig bleibt (hoffentlich) eine viel einfachere Aufgabe, an der dann gebastelt werden darf
- Theorie und Praxis sind keine Gegensätze!




- Ein Optimierungsproblem besteht aus einer **zulässigen Menge**  $G$  und einer **Zielfunktion**  $f : G \rightarrow \mathbb{R}$

- Beispiel:

$$f(x) = x^2$$


$$G = \{x \in \mathbb{R} \mid 2 \leq x \leq 5\}$$



- Minimum:**  $\min_x f(x) = 4$
- Minimierer:**  $\operatorname{argmin}_x f(x) = 2$
- Wir haben also ein Modell in Form einer Zielfunktion und möchten aus einer großen Anzahl möglicher Lösungen (zulässige Menge) die beste finden (Minimierer).

- Historisch stark verankert in “**Operations Research**”:  
Optimierung von Produktionskosten unter diversen Nebenbedingungen
- Fast alle modernen Verfahren aus dem **maschinellen Lernen** basieren auf Optimierung
- **Pfadplanung** basiert auf effizienten Optimierungsverfahren (z.B. kürzeste Pfade in Navigationssystemen)
- **Hardwaredesign** und **paralleles Rechnen** basiert auf der Optimierung von Layouts und Netzwerken
- **Computer Vision** basiert größtenteils auf Optimierung
- Große Teile der **Bioinformatik** nutzen Optimierungsverfahren

- Gegeben: Samples  $\mathbf{x}_n$  zweier Klassen:  $t_n \in \{-1, 1\}$
- Ziel: Finde lineare Entscheidungsgrenze  $y = \mathbf{w}^\top \mathbf{x} + b$  um ein neues Beispiel  $\mathbf{x}$  zu klassifizieren





1. Formuliere das Problem als Kostenfunktion

$$\operatorname{argmin}_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (\text{kleine Gewichte sind günstiger})$$

mit Nebenbedingungen

$$t_n(\mathbf{w}^\top \mathbf{x}_n + b) \geq 1 \quad (\text{alle Samples müssen richtig klassifiziert werden})$$

2. Dieses Optimierungsproblem ist ein **quadratisches Programm**  
→ kann mit Standardverfahren garantiert optimal gelöst werden



Finde die Oberfläche, die am besten alle  
Eingabebilder erklärt

$$\operatorname{argmin}_{u(\mathbf{X}) \in [0,1]} \int Ru + \nu \rho |\nabla u| d\mathbf{X}$$





- Ziel: Finde eine Kontur  $C$ , die das Bild In Vordergrund  $\Omega_1$  und Hintergrund  $\Omega_2$  aufteilt
- Beide Regionen werden durch die mittlere Helligkeit  $\mu_1, \mu_2$  modelliert
- Kürzere Konturen sind besser
- Kostenfunktion:

$$E(C) = \int_{\Omega_1} (I - \mu_1)^2 dx + \int_{\Omega_2} (I - \mu_2)^2 dx + \nu |C|$$

Kann mittels **Gradientenabstieg** minimiert werden




- Ziel: Erstellen einer Umgebungskarte und gleichzeitige Lokalisierung in der Karte (SLAM = simultaneous localization and mapping)
- Sensormessungen sind jeweils relativ zur Roboterposition  
→ Berücksichtigung aller Messungen in einem Optimierungsproblem
- Lösung mit  
**Gauss-Newton-Verfahren**
- Äquivalentes Problem (im Sinne der Optimierung) in Computer Vision: Bundle Adjustment




Autor: Cyrill Stachniss

- 3D-Rekonstruktion
- Gleichzeitige Optimierung von Kamera-Position und 3D-Objekt



C. Olsson, A. Eriksson, R. Hartley, CVPR 2010

- Für sicherheitsrelevante Systeme muss gezeigt werden, dass sie bestimmte Spezifikationen (mit einer bestimmten Wahrscheinlichkeit) erfüllen.
- Exploration sehr großer Zustandsräume
- Oft ist nur ein bestimmtes Teilsystem für die Abweichung von der Spezifikation verantwortlich
- Das kleinste relevante Teilsystem lässt sich mithilfe eines **linearen Programms** bestimmen.



Minimales kritisches Teilsystem

$$\begin{aligned}
 &\text{minimize} && -\frac{1}{2} p_{s_{\text{init}}} + \sum_{s \in S} x_s \\
 &\text{such that} \\
 &\forall s \in T_a : && p_s = x_s \\
 &\forall s \in S \setminus T_a : && p_s \leq x_s \\
 &\forall s \in S \setminus T_a : && p_s \leq \sum_{s' \in \text{succ}(s)} P(s, s') \cdot p_{s'} \\
 &&& p_{s_{\text{init}}} > \lambda .
 \end{aligned}$$

Mixed integer linear program

Quelle: Wimmer et al. 2012

- Sequenzalignment Basistechnologie zur Bestimmung der Evolution von Genen

*Dynamische Programmieren  $O(n^2)$*

- Anwendung auch zur Bestimmung der Ähnlichkeit ganzer Genome -> Hauptspeicher wird zum Problem

*Linear-Space mit Divide-and-Conquer*

- Erweiterung: Strukturelles Alignment ist NP-schwer

*Integer Linear Programming*

- Lokales Alignment: Alignment-Score wird durch die Alignment-Länge geteilt

*Fractional Programming*

```

1 MNPNQKIITIGSISIAIGIISLILQIGNIISIWASHSIQTGSQNHTGICNQR 52
...
53 IITYENSTWVNNTYVNNNTNVAEKDKTSVTLAGNSSLCSISGWAITYTKDN 104
1 .....VKLAGNSSLCPINGWAVYSKDN 22

105 SIRIGSKGDVVFVIREPFISCSHLECRTFFLTQGALLNDKHSNGTVKDRSPYR 156
23 SIRIGSKGDVVFVIREPFISCSHLECRTFFLTQGALLNDKHSNGTVKDRSPHR 74

157 TLMSCPLGEAPSPYNSRFESVAWSASACHDGMGWLTIGISGPDNGAVAVLKY 208
75 TLMSCPVGEAPSPYNSRFESVAWSASACHDGTSWLTIGISGPDNGAVAVLKY 126

209 NGIITETIKSWKKRILRTQESCEVCMNNGSCFTIMTDGSPNGAASYKIFKIEK 260
127 NGIITDTIKSWRNNILRTQESCECACVNGSCFTVMTDGPNGQASYKIFKMEK 178


261 GKVTKTIELNAPNFHYEESCYPDTGTVMCVCRDNWHSNRPWVSFNQNLDY 312
179 GKVVKSVELDAPNYHYEESCYPNAGEITCVCRDNWHSNRPWVSFNQNLLEY 230

313 DIGYICSGVFGDNPRPKDGEESCNPVTVDGADGVKGFYSKYGNNGVWIGRTKS 364
231 DIGYICSGVFGDNPRPNDGTSCGPVSSNGAYGVKGFYSKYGNNGVWIGRTKS 282






365 NRLRKGFEMIWDPNGWTNTDSDFSVKQDVVAITDWSGYSGSFVQHPELTGLD 416
283 TNSRSGFEMIWDPNGWTEITDSDFSVKQDVAITDWSGYSGSFVQHPELTGLD 334

417 CIRPCFWVELVRGLPRENTTIWTSGSSISFCGVNSGTANWS ..... 457
335 CIRPCFWVELIRGRPKE-STIWTSGSSISFCGVNSDTVGWSWFDGAELPFTI 385


```



- Probleme mit Nebenbedingungen vs. Probleme ohne Nebenbedingungen
- Optimierung mit kontinuierlichen Variablen vs. diskreten Variablen
- Lineare vs. nichtlineare Funktionen
- Eindimensionale vs. mehrdimensionale Funktionen
- Konvexe vs. nicht-konvexe Funktionen und Mengen (mehr dazu gleich)



- Problem:  $\min (x_1 - 2)^2 + (x_2 - 1)^2$  subject to  $x_1 + x_2 \leq 2$   
 $x_1^2 - x_2 \leq 0$
- Lösungsbereich:

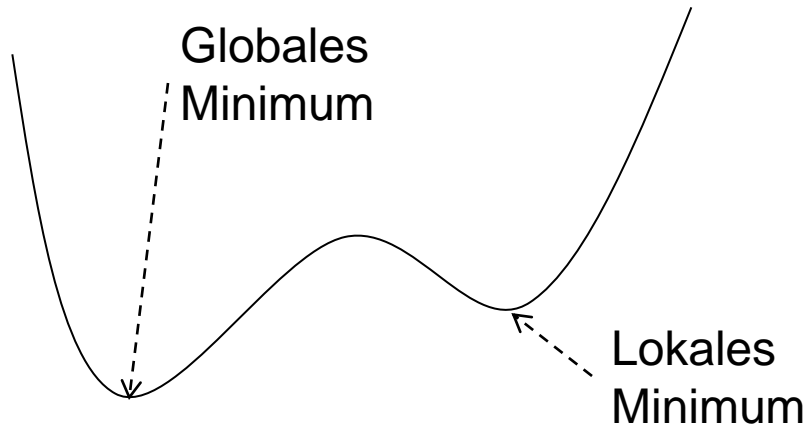


- Bem: allg. Kreisgleichung lautet  $(x_1 - M_1)^2 + (x_2 - M_2)^2 = r^2$



- Die verschiedenen Problemklassen (und ihre Kombinationen) sind unterschiedlich “schwierig”.
- Bei diskreten Optimierungsproblemen:
  - Lässt sich das Optimum **garantiert in polynomieller Zeit** finden?
  - Falls ja, wie groß ist die **Komplexität** des Optimierungsverfahrens?
  - Gibt es Approximationen mit Garantien bzgl. der maximalen Abweichung (obere/untere Schranken)?
- Bei kontinuierlichen Optimierungsproblemen:
  - Gibt es Verfahren, die in allen Fällen zu einer Lösung **konvergieren**?
  - Konvergiert das Verfahren garantiert zum **globalen Optimum**?
  - Wie schnell konvergiert das Verfahren (**Konvergenzordnung**)?





- Für ein **lokales Minimum**  $f(x^L)$  muss gelten


$$f(x^L) \leq f(x) \quad \forall x \in U(x^L)$$

Dabei ist  $U(x^L)$  eine Normkugel mit einem hinreichend kleinen Radius  $\epsilon > 0$ :

$$U(x^L) = \{x \in \mathbb{R}^n \mid \|x - x^L\| < \epsilon\}$$

- Für ein **globales Minimum**  $f(x^*)$  muss gelten

$$f(x^*) \leq f(x) \quad \forall x \in \mathbb{R}^n$$






Eindeutiges  
globales  
Optimum

Zusammenhängende  
Region globaler  
Optima

Mehrere globale  
Optima

Kann man feststellen, ob eine Optimierungsaufgabe “gutmütig” ist, also ein eindeutiges globales Minimum und keine weiteren lokalen Minima hat?




- Eine Menge  $G \subset \mathbb{R}^n$  ist konvex, wenn für beliebige Punkte  $x, y \in G$  auch die Verbindungslineie


$$[x, y] := \{z := (1 - \lambda)x + \lambda y | \lambda \in [0, 1]\}$$

in  $G$  enthalten ist:


$$x, y \in G \Rightarrow [x, y] \subset G$$

- Die **konvexe Hülle** einer Menge  $G$  ist die kleinste konvexe Menge, die  $G$  vollständig enthält.






konvex



nicht konvex



nicht konvex


- Eine über einer konvexen Menge  $G$  definierte Funktion  $f : G \rightarrow \mathbb{R}$  heißt **konvex**, falls

$$x, y \in G; x \neq y \Rightarrow f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y) \quad \forall \lambda \in [0, 1]$$


- Sie heißt **streng konvex**, falls

$$x, y \in G; x \neq y \Rightarrow f((1-\lambda)x + \lambda y) < (1-\lambda)f(x) + \lambda f(y) \quad \forall \lambda \in [0, 1]$$


- Eine streng konvexe Funktion besitzt ein eindeutiges globales Minimum und keine lokalen Minima.
- Eine konvexe Funktion kann mehrere globale Minima besitzen, jedoch keine zusätzlichen lokalen Minima.
- Eine nicht-konvexe Funktion, die keine weiteren lokalen Minima besitzt, wird als **quasikonvex** bezeichnet.




streng konvex



konvex



quasikonvex



nicht konvex

- Die Verbindungsline zwischen globalem und lokalem Minimum muss unterhalb des Graphen liegen!

- Vorlesung 1: Einführung
  - Vorlesung 2: Gradientenverfahren
  - Vorlesung 3: Newton- und Quasi-Newton-Verfahren
  - Vorlesung 4: Optimierung mit Nebenbedingungen
  - Vorlesung 5: Lineare Programme
  - Vorlesung 6: Quadratische Programme
  - Vorlesung 7: Nichtlineare Programme
  - Vorlesung 8: Kombinatorische Optimierung
- 
- Übung 1: Gradientenverfahren
  - Übung 2: Quasi-Newton-Verfahren
  - Übung 3: Nebenbedingungen
  - Übung 4: Lineare Programme
  - Übung 5: Projektionsmethoden

- Übungen
  - Mehrheitlich praktische Aufgaben in Python
  - Ziel: Gefühl für einige wichtige Verfahren
  - Ca. jede dritte Woche (genaue Information auf der Internetseite der Vorlesung)
- Prüfung
  - Schriftliche Prüfung
  - Unbedingt rechtzeitig zur Prüfung anmelden
  - Keine Zulassungsbeschränkungen
- Folien und weiteres Material im ILIAS unter:  
<https://ilias.uni-freiburg.de>  
Kurs "Optimierung"  
(Passwort: reinda)  
direkter Link in Kursseite auf  
<http://www.bioinf.uni-freiburg.de/Lehre>



- Sie sind erwachsene Menschen und Studenten einer **Universität**
- Fachwissen ist nicht das primäre Lernziel (vergleiche Fachhochschulen)
- Lernziele an der Universität:
  - Fähigkeit zu abstrahieren
  - Lernen mit Schwierigkeiten positiv umzugehen
  - Verantwortung übernehmen (zunächst für sich selbst)
  - Durchzuhalten auch wenn es mal keinen Spaß macht
- Nutzen Sie die Freiheit richtig und nehmen Sie diese Ratschläge mit:
  - Nehmen Sie die Übungen ernst
  - Arbeiten Sie den Stoff nach der Vorlesung noch einmal kurz durch
  - Füllen Sie Verständnislücken möglichst zügig (eigenständig, mit Kommilitonen, durch Fragen in der Vorlesung oder Übung)
  - Betreiben Sie bewusst Zeitmanagement (just in time is often just too late)

- J. Nocedal, S. J. Wright: Numerical Optimization, Springer, 2006.
- H. Jongen, K. Meer, E. Triesch: Optimization Theory, Kluwer, 2004.
- C. Großmann, J. Terno: Numerik der Optimierung, Teubner, 1997.
- H. Hamacher, K. Klamroth: Lineare Optimierung und Netzwerkoptimierung, Vieweg, 2006.
- M. S. Bazaraa, H. D. Sherali, C. M. Shetty: Nonlinear Programming, Wiley, 2006.
- R. Wimmer, B. Becker, N. Jansen, E. Abraham, J.-P. Katoen: Minimal critical subsystems for discrete-time Markov models, Proc. TACAS, Springer LNCS, pp. 299–314, 2012.