

# Optimierung

---

## Vorlesung 4 (Erweiterung) Erklärung Dualität


- Formulierung 1:  $\min_x f(x)$  subject to  $c_i(x) \geq 0, i \in \mathcal{I}$
- Dazugehörige Lagrangefunktion:  $\mathcal{L}(x, \lambda) = f(x) - \sum_i \lambda_i c_i(x)$
- Äquivalente Formulierung:  $\min_x f(x)$  subject to  $c_i(x) \leq 0, i \in \mathcal{I}$
- Dazugehörige Lagrangefunktion:  $\mathcal{L}(x, \lambda) = f(x) + \sum_i \lambda_i c_i(x)$

- Lagrangefunktion:  $\mathcal{L}(x, \lambda) = f(x) + \sum_i \lambda_i c_i(x)$
- Eigentlich wollen wir nicht  $\mathcal{L}(x, \lambda)$  minimieren, sondern folgende Funktion:

$$J(x) = \begin{cases} f(x) & \text{if } c_i(x) \leq 0 \\ \infty & \text{else} \end{cases}$$
$$= f(x) + \sum_i I[c_i(x)]$$


$$\text{with } I[u] = \begin{cases} 0 & \text{if } u \leq 0 \\ \infty & \text{else} \end{cases}$$

- Wir suchen also:  $\min_x J(x)$
- Problem:  $I[u]$  nicht differenzierbar



- Daher: Approximiere  $I[u]$  durch lineare Funktion  $\lambda_i \cdot u$
- Aus  $J(x) = f(x) + \sum_i I[c_i(x)]$  wird dann:

$$\mathcal{L}(x, \lambda) = f(x) + \sum_i \lambda_i c_i(x)$$



- Aus dem Bild sieht man sofort dass die Lagrange-Funktion eine untere Schranke ist:

$$\forall \lambda \geq 0 : \mathcal{L}(x, \lambda) \leq J(x)$$

- Gegeben ein festes  $x$ , was ist das “beste”  $\lambda_i$ ?

$$c_i(x) \leq 0 \quad \Rightarrow \quad \lambda_i = 0 \quad (\text{Bem.: } \lambda > 0 \text{ verkleinert da } c_i(x) \leq 0)$$

$$c_i(x) > 0 \quad \Rightarrow \quad \lambda_i \rightarrow \infty$$

- Daher gilt (etwas überraschend?):  $\max_{\lambda} \mathcal{L}(x, \lambda) = J(x)$

- Da wir an  $\min_x J(x)$  interessiert sind, suchen wir nach

$$\min_x \max_{\lambda} \mathcal{L}(x, \lambda) = \min_x J(x)$$

- Das ist aber vielleicht schwer, daher schauen wir mal auf

$$\max_{\lambda} \min_x \mathcal{L}(x, \lambda)$$

- Daraus leiten wir das duale Optimierungsproblem

$$\max_{\lambda} g(\lambda) \text{ wobei } g(\lambda) = \min_x \mathcal{L}(x, \lambda)$$

- Aus  $\forall \lambda \geq 0 : \mathcal{L}(x, \lambda) \leq J(x)$  folgt

$$\min_x \mathcal{L}(x, \lambda) = g(\lambda) \leq \min_x J(x)$$

- Damit ist  $\max_{\lambda} g(\lambda)$  das Problem des Findens der besten unteren Schranke
- Wird das duale Problem genannt und ist einfacher, da konkav (siehe später)

- Durch die Nebenbedingungen kamen neben den primalen Variablen  $x$  die Lagrange Multiplikatoren  $\lambda$  als Variablen ins Spiel

$$\mathcal{L}(x, \lambda) = f(x) + \sum_i \lambda_i c_i(x), \quad \lambda \geq 0$$

- Sie geben an wie stark die Funktion gegen die Bedingungen drückt.

$$\nabla f(x) = \lambda^\top \nabla c(x), \quad \lambda \geq 0$$

- Alternativ können wir  $\mathcal{L}(x, \lambda)$  als zu minimierende Funktion ohne Nebenbedingungen betrachten, indem wir  $\lambda$  festhalten

$$q(\lambda) = \min_x \mathcal{L}(x, \lambda) \quad *$$

- In vielen Fällen erhält man  $-\infty$  für einige Werte von  $\lambda$ . Daher schränken wir die Definitionsmenge von  $q(\lambda)$  entsprechend ein:

$$\mathcal{D} = \{\lambda \mid q(\lambda) > -\infty\}$$


- **Anmerkung:** 1.) Wir betrachten nur Ungleichheitsbed.

\*.) eigentlich sollten wir inf statt min betrachten

- Die Funktion

$$q(\lambda) = \min_x \mathcal{L}(x, \lambda)$$

ist konkav.



- Beweis Schritt 1: Wir zeigen

$$\mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) = (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1)$$

- Teilbeweis aus def. Lagrange:

$$\begin{aligned} \mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) &= f(x) + (1-\alpha)\lambda_0 c(x) + \alpha\lambda_1 c(x) \\ &= (1-\alpha)f(x) + \alpha f(x) + (1-\alpha)\lambda_0 c(x) + \alpha\lambda_1 c(x) \\ &= (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1) \end{aligned}$$


- Damit haben wir:

$$\mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) = (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1)$$

- Beweis (fort.)
- Das Infimum einer **Summe** ist größer gleich der Summe von Infima, daher:

$$q((1-\alpha)\lambda_0 + \alpha\lambda_1) \geq (1-\alpha)q(\lambda_0) + \alpha q(\lambda_1)$$

- Damit ist Konkavität bewiesen



$$\inf(f(x) + g(x)) \geq \inf f(x) + \inf g(x)$$



- Aus dem primalen Optimierungsproblem

$$\min_x f(x), \quad c_i(x) \leq 0$$

können wir also ein **duales Optimierungsproblem** ableiten

$$\max_{\lambda} \min_x \mathcal{L}(x, \lambda), \quad \lambda \geq 0$$

- In manchen Fällen lässt sich das duale Problem leichter lösen als das primale Problem.
- Sogenannte Primal-Dual-Verfahren optimieren gleichzeitig das primale und das duale Problem.
- Es gibt noch andere Formen der Dualität, z.B. die Fenchel Dualität.

- **Schwache Dualität:**

Für alle gültigen Lösungen  $x$  und  $\lambda$  gilt  $q(\lambda) \leq f(x)$

**Beweis:** 
$$q(\lambda) = \inf_x f(x) + \lambda^\top c(x) \leq f(x) + \underbrace{\lambda^\top c(x)}_{\leq 0} \leq f(x)$$

d.h. das duale Problem liefert immer eine untere Schranke für das primale Problem

- **Starke Dualität:**

- $f(x)$  sei konvex und die gültige Menge sei eine konvexe Menge
- $\hat{\lambda}$  bezeichne das Optimum von  $q(\lambda)$  mit  $\hat{x} = \operatorname{arginf}_x \mathcal{L}(x, \hat{\lambda})$
- $\mathcal{L}(x, \hat{\lambda})$  sei streng konvex

Dann gilt:

$$q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda}) = f(\hat{x})$$

d.h. das Optimum des dualen Problems minimiert auch das primale Problem.

- Konkaves Beispielproblem:

$$\min_{x_1, x_2} \frac{1}{2}(x_1^2 + x_2^2), \quad 1 - x_1 \leq 0$$

- Lagrange-Funktion:

$$\mathcal{L}(x_1, x_2, \lambda) = \frac{1}{2}(x_1^2 + x_2^2) + \lambda(1 - x_1)$$

- Bedingungen für ein Minimum:


$$x_1 - \lambda = 0, \quad x_2 = 0,$$

- Damit lässt sich  $x_1, x_2$  in der Lagrange-Funktion eliminieren (geht nicht immer analytisch). Es bleibt das duale Problem

$$\max q(\lambda) = \max -\frac{1}{2}\lambda^2 + \lambda, \quad \lambda \geq 0$$

mit der Lösung  $\lambda = 1$

- Lösung des primalen Problems (starke Dualität):  $x_1 = \lambda = 1, \quad x_2 = 0$



- **Lineare Programme**

$$\min_x w^\top x, \quad Ax - b \geq 0$$

- **Quadratische Programme**

$$\min_x \frac{1}{2} x^\top Q x + w^\top x, \quad Ax - b \geq 0$$

mit  $Q$  symmetrisch und positiv definit

- Optimalitätsbedingungen für Probleme mit Nebenbedingungen unterscheiden ob eine Bedingung aktiv oder inaktiv ist.
- Beide Fälle lassen sich mithilfe der Lagrange-Funktion ausdrücken.
- Über die Lagrange-Funktion lässt sich auch ein duales Problem herleiten.
- Die Lösung des dualen Problems bildet mindestens eine untere Schranke für das ursprüngliche Problem (schwache Dualität).
- Für konvexe Funktionen mit konvexen Nebenbedingungen führt die Lösung des dualen Problems zur exakten Lösung des ursprünglichen Problems (starke Dualität).

- Optimierungsproblem:

$$\min_x (x_1 - 3)^2 + (x_2 - 1)^2$$

$$1 - x_1 - x_2 \geq 0$$

$$1 + x_1 - x_2 \geq 0$$

$$1 - x_1 + x_2 \geq 0$$

$$1 + x_1 + x_2 \geq 0$$

- Machen Sie eine Skizze des erlaubten Suchraums.
- Berechnen Sie für verschiedene Punkte des Suchraums den Gradienten der Funktion und tragen Sie ihn in die Skizze ein.
- Wo befindet sich das Minimum?
- Wie sehen die Lagrange Multiplikatoren im Optimum aus? Welche Nebenbedingungen sind im Optimum aktiv, welche nicht?