


# Optimierung


---

## Vorlesung 4 Optimierung mit Nebenbedingungen



Gradientenabstieg

(allgemeines Verfahren für kontinuierliche Probleme)



Newton-Verfahren

(schnelle Konvergenz durch Ausnutzen der Krümmung)

$$d^k = -Q^k \nabla f(x^k)$$

Quasi-Newton-Verfahren (BFGS)

(effiziente Approximation der Krümmung)

- Bisher war der Suchraum für ein Optimum der gesamte Raum  $\mathbb{R}^n$
- In vielen Fällen ist der Suchraum  $G \subset \mathbb{R}^n$  eingeschränkt durch Nebenbedingungen, z.B.



$$x \leq 5$$

$$x \geq 2$$

- Die Lösung des Problems ohne Nebenbedingung ist immer eine **untere Schranke** für das Problem mit Nebenbedingung:

$$f(x \in \mathbb{R}^n) \leq f(x \in G)$$

- Oft (aber nicht immer) liegt das Optimum auf dem Rand von  $G$ .



- Jedes Optimierungsproblem lässt sich allgemein schreiben als:


$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{subject to} \quad \begin{cases} c_i(x) = 0, & i \in \mathcal{E} \\ c_i(x) \geq 0, & i \in \mathcal{I} \end{cases}$$

- Zwei Arten von Bedingungen:

- Gleichheitsbedingungen
- Ungleichheitsbedingungen

- Jede Bedingung lässt sich in diese Form bringen, z.B.

$$5x_1 + 3x_2 \leq 2 \quad \rightarrow \quad 2 - 5x_1 - 3x_2 \geq 0$$




- Das Problem:  $f(x) = x_1 + x_2$      $c(x) = x_1^2 + x_2^2 - 2 = 0$
- Gradienten von  $\nabla f$  und  $\nabla c$
- Schritt  $d$  erlaubt falls  $\nabla c^T d = 0$  und  $\nabla f^T d < 0$   
*also Abstieg in  $f$  und keine Änderung in  $c$*

- Im Minimum sind die Gradienten  $\nabla f$  und  $\nabla c$  offenbar parallel, d.h.

$$\nabla f(x) = \lambda \nabla c(x)$$

für einen bestimmten skalaren Wert

- In der Tat ist dies eine notwendige Bedingung für ein Minimum
- Offensichtlich ist die Bedingung nicht hinreichend, denn sie ist auch im Maximum erfüllt



- Wir können die notwendige Bedingung für ein Minimum mithilfe der **Lagrange Funktion** ausdrücken

$$\mathcal{L}(x, \lambda) = f(x) - \lambda c(x)$$

- Die Bedingung lautet dann

$$\nabla_x \mathcal{L}(x, \lambda) = \nabla f(x) - \lambda \nabla c(x) = 0$$

für ein geeignete Wahl von  $\lambda$

- Man bezeichnet  $\lambda$  auch als **Lagrange Multiplikator**
- In manchen Fällen nimmt dieser auch den Wert 0 an. Was bedeutet das?

- Betrachten wir das Problem

$$f(x) = (x_1 + x_2)^2$$


$$c(x) = x_1^2 + x_2^2 - 2 = 0$$

- Wir haben zwei (gleich gute) Minima.
- In beiden Fällen ist  $\nabla f = 0$ , d.h. unabhängig von  $c$  kann  $f$  lokal nicht weiter minimiert werden

- Die notwendige Bedingung

$$\nabla_x \mathcal{L}(x, \lambda) = \nabla f(x) - \lambda \nabla c(x) = 0$$

wird für  $\lambda = 0$  erfüllt.




- Das Problem:

$$f(x) = x_1 + x_2$$

$$c(x) = 2 - x_1^2 - x_2^2 \geq 0$$

- Wir betrachten einen Punkt  $x$  und fragen uns wann ein kleiner Schritt  $d$  zulässig ist.





- Das Problem:

$$f(x) = x_1 + x_2$$

$$c(x) = 2 - x_1^2 - x_2^2 \geq 0$$


- Minimum am Rand: wir wollen in Richtung  $-\nabla f$  aber ein weiterer Abstieg wird durch  $c$  verhindert

$$c(x) = 0$$

- Die Gradienten  $\nabla f$  und  $\nabla c$  zeigen im Minimum notwendigerweise in die gleiche Richtung

$$\nabla f(x) = \lambda \nabla c(x), \quad \lambda \geq 0$$

- Das Vorzeichen von  $\lambda$  spielt diesmal eine Rolle. Würden  $\nabla f$  und  $\nabla c$  in entgegengesetzte Richtung zeigen, könnte man  $f$  in Richtung von  $\nabla c$  weiter minimieren.



- Neues Problem:

$$f(x) = x_1^2 + x_2^2$$

$$c(x) = 2 - x_1^2 - x_2^2 \geq 0$$


- Das Minimum liegt nun im Inneren von  $G$ , d.h.  $c$  hat keinen Einfluss und  $\nabla f(x) = 0$

- Die Bedingung

$$\nabla f(x) = \lambda \nabla c(x), \quad \lambda \geq 0$$

ist für  $\lambda = 0$  erfüllt.

- Die Nebenbedingung ist hier im Minimum **inaktiv**.



- Wir können allgemein wieder die Lagrange Funktion

$$\mathcal{L}(x, \lambda) = f(x) - \lambda c(x), \quad \lambda \geq 0$$

verwenden und erhalten die **Optimalitätsbedingung**

$$\nabla_x \mathcal{L}(x, \lambda) = \nabla f(x) - \lambda \nabla c(x) = 0, \quad \lambda \geq 0$$

- Zusätzlich muss die **Komplementaritätsbedingung** gelten:

$$\lambda c(x) = 0$$


- Entweder liegt das Optimum auf dem Rand (dann ist  $c(x) = 0$ ) oder  $c$  ist im Optimum inaktiv (dann ist  $\lambda = 0$ ) oder beides.
- Sämtliche Fälle sind also sehr elegant über die Lagrange Funktion und die Komplementaritätsbedingung abgedeckt.
- Strenge Komplementarität** liegt vor wenn  $c$  und  $\lambda$  nicht gleichzeitig null sind

- Problem mit zwei Bedingungen:

$$f(x) = x_1 + x_2$$

$$c_1(x) = 2 - x_1^2 - x_2^2 \geq 0$$

$$c_2(x) = x_2 \geq 0$$



- In diesem Fall sind beide Nebenbedingungen im Minimum aktiv

$$\nabla f(x) - \lambda_1 \nabla c_1(x) - \lambda_2 \nabla c_2(x) = 0, \quad \lambda_1 \geq 0, \lambda_2 \geq 0$$

$$\text{d.h. } c_1(x) = c_2(x) = 0, \quad \lambda_1 > 0, \lambda_2 > 0$$

- Die Menge der aktiven Nebenbedingungen wird als die **aktive Menge** (active set) bezeichnet

- Einige Nebenbedingungen können überflüssig sein, da sie bereits von anderen Nebenbedingungen abgedeckt sind, z.B.:

$$c_1(x) = x_2 \geq 0$$

$$c_2(x) = x_2 \geq 2$$

- $c_2$  deckt automatisch auch  $c_1$  ab.  $c_1$  ist daher nie aktiv.
- Da die Komplexität von der Anzahl der Nebenbedingungen abhängt, ist es meist ratsam redundante Bedingungen vorab zu eliminieren.

- Zusammenfassend sind die notwendigen Bedingungen für ein lokales Optimum:

$$\nabla_x \mathcal{L}(x, \lambda) = 0$$

$$c_i(x) = 0, \quad \forall i \in \mathcal{E}$$

$$c_i(x) \geq 0, \quad \forall i \in \mathcal{I}$$

$$\lambda_i \geq 0, \quad \forall i \in \mathcal{I}$$

$$\lambda_i c_i(x) = 0, \quad \forall i \in \mathcal{E} \cup \mathcal{I}$$

- Diese werden als Karush-Kuhn-Tucker (KKT) Bedingungen bezeichnet.
- Im folgenden werden wir alle Bedingungen  $c_i(x)$  in einen Funktionsvektor  $c(x) := (c_1(x), \dots, c_m(x))^T$  und entsprechend  $\lambda \in \mathbb{R}^m$  zusammenfassen.

- Durch die Nebenbedingungen kamen neben den primalen Variablen  $x$  die Lagrange Multiplikatoren  $\lambda$  als Variablen ins Spiel

$$\mathcal{L}(x, \lambda) = f(x) - \lambda^\top c(x), \quad \lambda \geq 0$$

- Sie geben an wie stark die Funktion gegen die Bedingungen drückt.

$$\nabla f(x) = \lambda^\top \nabla c(x), \quad \lambda \geq 0$$

- Alternativ können wir  $\mathcal{L}(x, \lambda)$  als zu minimierende Funktion ohne Nebenbedingungen betrachten, indem wir  $\lambda$  festhalten

$$q(\lambda) = \inf_x \mathcal{L}(x, \lambda)$$

- In vielen Fällen erhält man  $-\infty$  für einige Werte von  $\lambda$ . Daher schränken wir die Definitionsmenge von  $q(\lambda)$  entsprechend ein:


$$\mathcal{D} = \{\lambda | q(\lambda) > -\infty\}$$

- **Anmerkung:** Wir betrachten nur Ungleichheitsbed.

- Die Funktion

$$q(\lambda) = \inf_x \mathcal{L}(x, \lambda)$$

ist konkav.



- Beweis Schritt 1: Wir zeigen

$$\mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) = (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1)$$

- Teilbeweis aus def. Lagrange:

$$\begin{aligned} \mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) &= f(x) - (1-\alpha)\lambda_0 c(x) - \alpha\lambda_1 c(x) \\ &= (1-\alpha)f(x) + \alpha f(x) - (1-\alpha)\lambda_0 c(x) - \alpha\lambda_1 c(x) \\ &= (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1) \end{aligned}$$




- Damit haben wir:

$$\mathcal{L}(x, (1-\alpha)\lambda_0 + \alpha\lambda_1) = (1-\alpha)\mathcal{L}(x, \lambda_0) + \alpha\mathcal{L}(x, \lambda_1)$$

- Beweis (fort.)
- Das Infimum einer **Summe** ist größer gleich der Summe von Infima, daher:

$$q((1-\alpha)\lambda_0 + \alpha\lambda_1) \geq (1-\alpha)q(\lambda_0) + \alpha q(\lambda_1)$$

- Damit ist Konkavität bewiesen (siehe Abb. oben)



$$\inf f(x) + \inf g(x) \geq \inf(f(x) + g(x))$$

- Aus dem primalen Optimierungsproblem

$$\min_x f(x), \quad c(x) \geq 0$$

können wir also ein **duales Optimierungsproblem** ableiten

$$\max_{\lambda} \inf_x \mathcal{L}(x, \lambda), \quad \lambda \geq 0$$

- In manchen Fällen lässt sich das duale Problem leichter lösen als das primale Problem.
- Sogenannte Primal-Dual-Verfahren optimieren gleichzeitig das primale und das duale Problem.
- Es gibt noch andere Formen der Dualität, z.B. die Fenchel Dualität.

- **Schwache Dualität:**

Für alle gültigen Lösungen  $x$  und  $\lambda$  gilt  $q(\lambda) \leq f(x)$

**Beweis:** 
$$q(\lambda) = \inf_x f(x) - \lambda^\top c(x) \leq f(x) - \underbrace{\lambda^\top c(x)}_{\geq 0} \leq f(x)$$

d.h. das duale Problem liefert immer eine untere Schranke für das primale Problem

- **Starke Dualität:**

- $f(x)$  sei konvex und die gültige Menge sei eine konvexe Menge
- $\hat{\lambda}$  bezeichne das Optimum von  $q(\lambda)$  mit  $\hat{x} = \operatorname{arginf}_x \mathcal{L}(x, \hat{\lambda})$
- $\mathcal{L}(x, \hat{\lambda})$  sei streng konvex

Dann gilt:

$$q(\hat{\lambda}) = \mathcal{L}(\hat{x}, \hat{\lambda}) = f(\hat{x})$$

d.h. das Optimum des dualen Problems minimiert auch das primale Problem.

- Konkaves Beispielproblem:

$$\min_{x_1, x_2} \frac{1}{2}(x_1^2 + x_2^2), \quad x_1 - 1 \geq 0$$

- Lagrange-Funktion:

$$\mathcal{L}(x_1, x_2, \lambda) = \frac{1}{2}(x_1^2 + x_2^2) - \lambda(x_1 - 1)$$

- Bedingungen für ein Minimum:


$$x_1 - \lambda = 0, \quad x_2 = 0,$$

- Damit lässt sich  $x_1, x_2$  in der Lagrange-Funktion eliminieren (geht nicht immer analytisch). Es bleibt das duale Problem

$$\max q(\lambda) = \max -\frac{1}{2}\lambda^2 + \lambda, \quad \lambda \geq 0$$

mit der Lösung  $\lambda = 1$

- Lösung des primalen Problems (starke Dualität):  $x_1 = \lambda = 1, \quad x_2 = 0$



- **Lineare Programme**

$$\min_x w^\top x, \quad Ax - b \geq 0$$

Duales Problem:

$$\max_{\lambda} b^\top \lambda, \quad A^\top \lambda = w, \quad \lambda \geq 0$$

- **Quadratische Programme**

$$\min_x \frac{1}{2} x^\top Q x + w^\top x, \quad Ax - b \geq 0$$

mit  $Q$  symmetrisch und positiv definit

Duales Problem:

$$\max_{\lambda} -\frac{1}{2} (A^\top \lambda - w)^\top Q^{-1} (A^\top \lambda - w) + b^\top \lambda, \quad \lambda \geq 0$$

- Optimalitätsbedingungen für Probleme mit Nebenbedingungen unterscheiden ob eine Bedingung aktiv oder inaktiv ist.
- Beide Fälle lassen sich mithilfe der Lagrange-Funktion ausdrücken.
- Über die Lagrange-Funktion lässt sich auch ein duales Problem herleiten.
- Die Lösung des dualen Problems bildet mindestens eine untere Schranke für das ursprüngliche Problem (schwache Dualität).
- Für konvexe Funktionen mit konvexen Nebenbedingungen führt die Lösung des dualen Problems zur exakten Lösung des ursprünglichen Problems (starke Dualität).

- Optimierungsproblem:

$$\min_x (x_1 - 3)^2 + (x_2 - 1)^2$$

$$1 - x_1 - x_2 \geq 0$$

$$1 + x_1 - x_2 \geq 0$$

$$1 - x_1 + x_2 \geq 0$$

$$1 + x_1 + x_2 \geq 0$$

- Machen Sie eine Skizze des erlaubten Suchraums.
- Berechnen Sie für verschiedene Punkte des Suchraums den Gradienten der Funktion und tragen Sie ihn in die Skizze ein.
- Wo befindet sich das Minimum?
- Wie sehen die Lagrange Multiplikatoren im Optimum aus? Welche Nebenbedingungen sind im Optimum aktiv, welche nicht?